

Clasificación

Clasificadores Bayesianos

Clasificadores Bayesianos

- Modela **relaciones probabilísticas** entre el conjunto de atributos y el atributo clase
- **Probabilidad condicional**: probabilidad de que una variable aleatoria pueda tomar un valor particular dado el valor de otra variable aleatoria

$$P(Y=y \mid X=x)$$

se refiere a la probabilidad que la variable **Y** puede tomar el valor de **y** dado que la variable **X** toma el valor de **x**

Teorema de Bayes

- Las probabilidades condicionales de X y Y estan relacionadas:

$$P(X,Y) = P(Y|X) P(X) = P(X|Y) P(Y)$$

- **Teorema de Bayes**

$$P(Y|X) = P(X|Y) \cdot P(Y) / P(X)$$

- Ejercicio

Football: 2 equipos. Equipo 0 gana el 65%, equipo 1 gana 35%. De los juegos ganados por el equipo 0, el 30% son jugados en la cancha del equipo 1. El 75%, de las victorias del equipo 1 son ganados cuando juegan en casa. Si el equipo 1 es local el siguiente juego, cual equipo es el favorito a ganar?

Ejemplo

- X variable aleatoria que representa el equipo local
- Y variable aleatoria que representa el ganador
- Probabilidad que equipo 0 gane: $P(Y=0) = 0.65$
- Probabilidad que equipo 1 gane: $P(Y=1) = 0.35$
- Probabilidad de que el equipo 1 juegue como local gane:

$$P(X=1|Y=1) = 0.75$$

- Probabilidad de que el equipo 1 juegue como local y equipo 0 gane:

$$P(X=1|Y=0) = 0.3$$

Ejemplo

- Objetivo

$P(Y=1|X=1)$ probabilidad condicional de que el equipo 1 gane el siguiente juego estando como local, y comparar con $P(Y=0|X=1)$

- Usando Bayes

$$\begin{aligned} P(Y=1|X=1) &= P(X=1|Y=1) P(Y=1) / P(X=1) \quad \text{Ley de probabilidad total} \\ &= P(X=1|Y=1) P(Y=1) / P(X=1, Y=1) + P(X=1, Y=0) \\ &= P(X=1|Y=1) P(Y=1) / P(X=1|Y=1)P(Y=1) + P(X=1|Y=0)P(Y=0) \\ &= 0.75 \times 0.35 / (0.75 \times 0.35 + 0.3 \times 0.65) = 0.5738 \end{aligned}$$

- $P(Y=0|X=1) = 1 - P(Y=1|X=1) = 0.4262$

Equipo1 tiene mas oportunidad de ganar

Clasificador Bayesiano

- X conjunto de atributos
- Y clase
- X y Y tratadas como variables aleatorias y la relación probabilística entre ellas es

$$P(Y|X)$$

Probabilidad posterior para Y

En el entrenamiento las probabilidades posteriores por cada combinación de X y Y son obtenidas

Clasificador Bayesiano

- El problema puede ser formalizado usando probabilidades **a-posteriori**

$P(Y|X)$ = probabilidad que el ejemplo $X = \langle x_1, \dots, x_k \rangle$ sea de la clase Y .

- Conjunto de test X' puede ser clasificado encontrando la clase Y' que **maximice** la **probabilidad posterior** $P(Y'|X')$

Problema de tomar una decisión

Dada las condiciones del clima, es posible jugar tennis?

Outlook	Temperature	Humidity	Windy	Class
sunny	hot	high	false	N
sunny	hot	high	true	N
overcast	hot	high	false	P
rain	mild	high	false	P
rain	cool	normal	false	P
rain	cool	normal	true	N
overcast	cool	normal	true	P
sunny	mild	high	false	N
sunny	cool	normal	false	P
rain	mild	normal	false	P
sunny	mild	normal	true	P
overcast	mild	high	true	P
overcast	hot	normal	false	P
rain	mild	high	true	N

Estimando probabilidades posteriores

- Teorema de Bayes: $P(Y|X) = P(X|Y) \cdot P(Y) / P(X)$
- $P(X)$ es constante por todas las clases (puede ser ignorado)
- $P(Y)$ = (prior probabilities): $P(Y_i) = s_i/s$
- Y tal que $P(Y|X)$ es maxima=
Y tal que $P(X|Y) \cdot P(Y)$ is maxima
- Problema: computo de $P(X|Y)$ no es disponible!

Naive Bayes Clasifier y Bayesian belief Network

Naïve Bayesian Classification

- Supuesto “Naïve”: independencia de atributos

$$P(x_1, \dots, x_k | Y) = P(x_1 | Y) \cdot \dots \cdot P(x_k | Y)$$

- Si i-esimo atributo es categórico:

$P(x_i | Y)$ es estimado como la frecuencia relativa de ejemplos que tienen valor x_i como i-esimo atributo en clase Y:

- $P(x_i | Y) = \frac{\text{\# de ejemplos en clase Y w/ i-th atributo} = x_i}{\text{\# de ejemplos en clase Y}}$

Naïve Bayesian Classification

- Si i -ésimo atributo es **continuo**:

$P(x_i|Y_j)$ es estimado con la función de densidad Gauss

- compute mean ($\mu_{j,i}$) and stand. Deviation ($\sigma_{j,i}$) for EACH attribute (i) using data from j -th class (C_j) only
- Densities:

$$P(x_i | Y_j) = \frac{1}{\sqrt{2\pi}\sigma_{j,i}} e^{-\frac{(x_i - \mu_{j,i})^2}{2\sigma_{j,i}^2}}$$

Probabilidades condicionales por clase

$P(x_i|Y_j)$

- Computo de probabilidades(4 atributos, 2 clases)
- 14 ejemplos (9 positivos, 5 negativos)

Outlook	P	N		Humidity	P	N
sunny	2/9	3/5		high	3/9	4/5
overcast	4/9	0		normal	6/9	1/5
rain	3/9	2/5				
Temperature				Windy		
hot	2/9	2/5		true	3/9	3/5
mild	4/9	2/5		false	6/9	2/5
cool	3/9	1/5				

Ejemplo:

- Nuevo ejemplo $X = \langle \text{rain, hot, high, false} \rangle$

$$P(Y|X) = P(X|Y) \cdot P(Y)$$

- $P(X|p) \cdot P(p) =$
 $P(\text{rain}|p) \cdot P(\text{hot}|p) \cdot P(\text{high}|p) \cdot P(\text{false}|p) \cdot P(p) =$
 $3/9 \cdot 2/9 \cdot 3/9 \cdot 6/9 \cdot 9/14 = 0.010582$

- $P(X|n) \cdot P(n) =$
 $P(\text{rain}|n) \cdot P(\text{hot}|n) \cdot P(\text{high}|n) \cdot P(\text{false}|n) \cdot P(n) =$
 $2/5 \cdot 2/5 \cdot 4/5 \cdot 2/5 \cdot 5/14 = 0.018286$

- Ejemplo X is clasificado en clase n (No jugar)

Supuesto de independencia

- ... computacion posible
- ... optimo clasificador cuando el supuesto se satisface
- ... pero raro en la realidad, en la mayoría los atributos son correlacionados
- Intentos de manejar esta limitación:
 - **Redes Bayesianas**, combinan el razonamiento bayesiano con causal relationships (relaciones casuales) entre atributos
 - **Árboles de decisión**, analiza un atributo a la vez, considerando los mas importantes atributos primero

Bayesian Belief Networks

Redes Bayesianas

- Modelar la probabilidad condicional de clases


$P(X|Y)$ sin el supuesto de independencia

- Permite **especificar** que par de atributos son condicionalmente independientes

1. Representación y construcción del modelo
2. Inferencia sobre el modelo


Representación del modelo

- Representación grafica de las relaciones probabilísticas entre el conjunto de variables aleatorias.
 - Grafo dirigido aciclico (representa las relaciones dependientes entre variables)
 - Tabla de probabilidades (asociando cada nodo con sus nodos padres)



A y B variables independientes. Cada una tiene Influencia en la variable C
A y B son **padres** de C
C es **hijo** de A y B

Representación del modelo (2)



Path directo

D es **ancestro** de B

A es **descendente** de D

B **no es descendente** de A

D **no es descendente** de A

Un nodo en una red bayesiana es condicionalmente independiente de sus no descendientes, si sus padres son conocidos

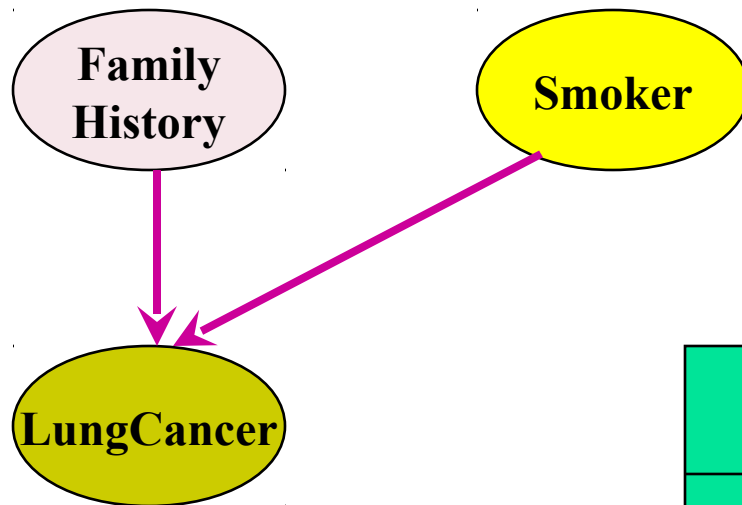
Representación del modelo (3)

■ Tabla de probabilidades

- Si el nodo X no tiene padres, la tabla contiene la probabilidad a priori $P(X)$
- Si el nodo X tiene solo un padre, Y , entonces la tabla contiene la probabilidad condicional $P(X|Y)$
- Si el nodo X tiene varios padres $\{Y_1, Y_2, \dots, Y_k\}$ entonces la tabla contiene la probabilidad condicional $P(X|Y_1, Y_2, \dots, Y_k)$

Representación del modelo (4)

Valores binarios



(FH, S) (FH, ~S) (~FH, S) (~FH, ~S)

	(FH, S)	(FH, ~S)	(~FH, S)	(~FH, ~S)
LC	0.8	0.5	0.7	0.1
~LC	0.2	0.5	0.3	0.9

Construcción del modelo

1. Crear la estructura de la red
 - Algoritmos para generar la topología (garantizar no hay ciclos)
1. Estimar las probabilidades en tablas asociadas a cada nodo

Basic Inference






$$\underbrace{P(b)} = \sum_a P(a, b) = \sum_a P(b \mid a) P(a)$$

$$P(c) = \sum_b P(c \mid b) \underbrace{P(b)}$$

$$P(c) = \sum_{b,a} P(a, b, c) = \sum_{b,a} P(c \mid b) P(b \mid a) P(a)$$

$$= \sum_b P(c \mid b) \underbrace{\sum_a P(b \mid a) P(a)}_{P(b)}$$

Ejemplo: Modelar pacientes con enfermedad del corazón o problemas de gastritis



Variables binarias

Ejemplo: generando la topología de la red

- Variables ordenadas (E,D,HD,Hb,CP,BP)

$$P(D|E)$$

$$P(D)$$

$$P(HD|E, D)$$

$$P(HD|E, D) \text{ No se puede simplificar}$$

$$P(Hb|HD,E,D)$$

$$P(Hb,D)$$

$$P(CP|Hb,HD,E,D)$$

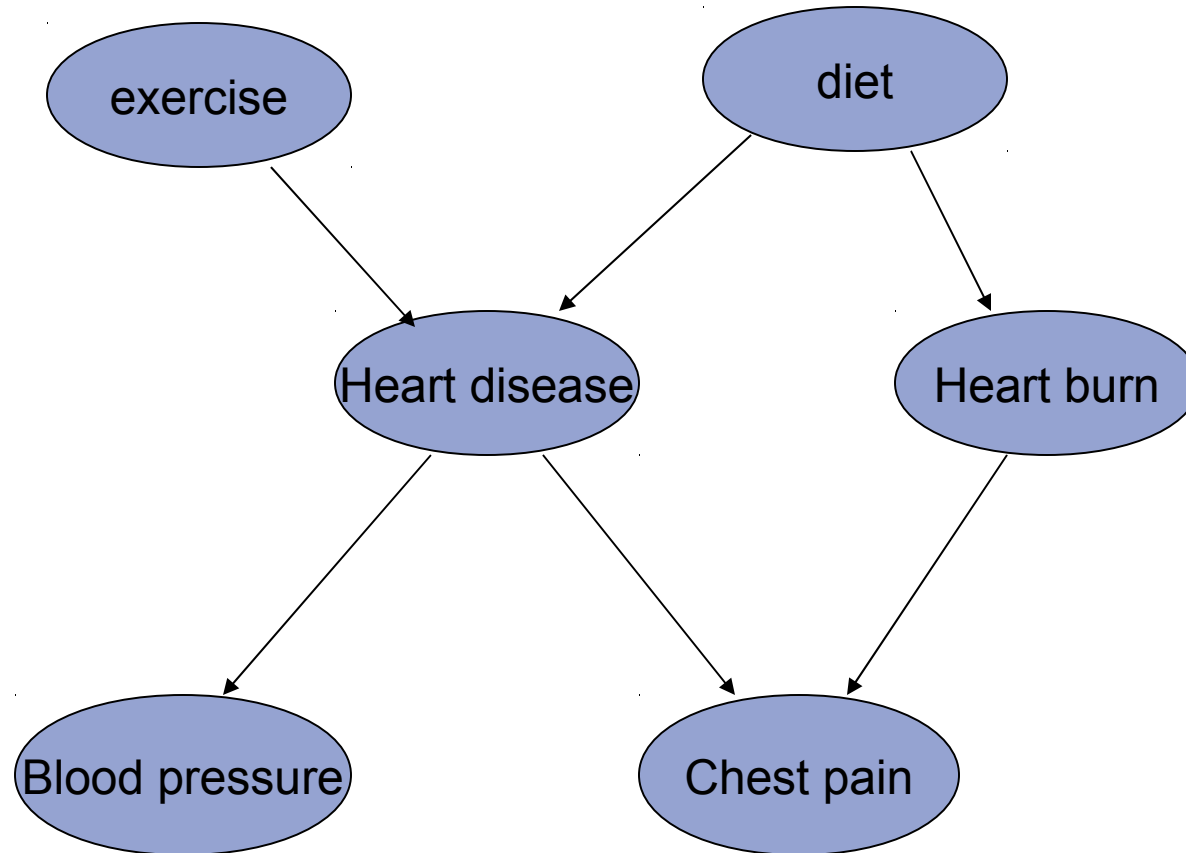
$$P(CP|Hb,HD)$$

$$P(BP|CP,Hb,HD,E,D)$$

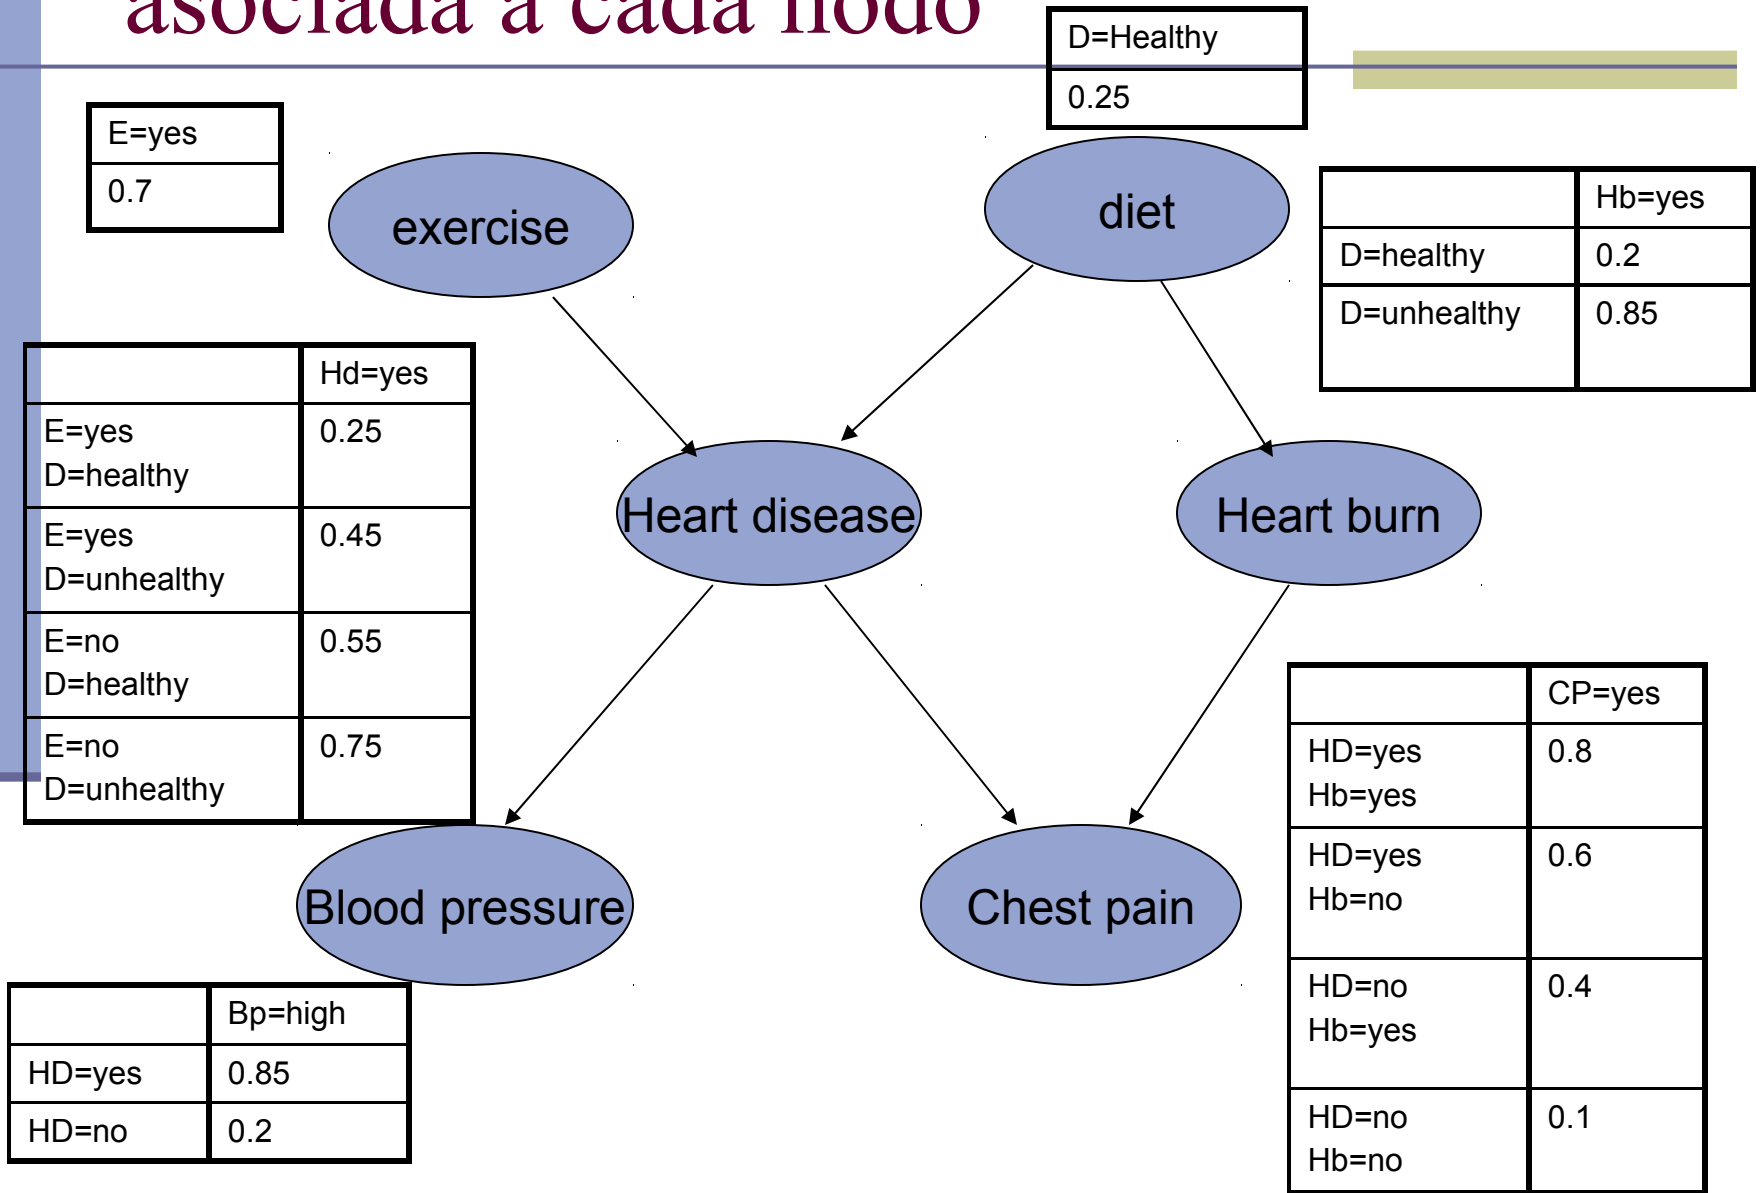
$$P(BP|HD)$$

- Basados en las probabilidades condicionales se crean los arcos entre nodos:
(E,HD),(D,HD),(D,Hb),(HD,CP),(Hb,CP) y (HD,BP)

Ejemplo: Estructura de red



Ejemplo: tabla de probabilidades asociada a cada nodo



Ejemplo: Inferencia

- Diagnosticar cuando una persona esta enferma del corazón.
- Diagnostico puede ser hecho desde diferentes escenarios:
 1. Sin información previa
 2. Alta presión (High Blood pressure)
 3. Alta presión, dieta saludable (Healthy diet) y ejercicio regular (regular exercise)

1. Sin información previa

- Se puede determinar computando las probabilidades a priori:

$$P(HD=yes) \text{ y } P(HD=no)$$

Supongamos:

$\alpha \in \{yes, no\}$ valores de **exercise**

$\beta \in \{healthy, unhealthy\}$ valores de **diet**

$$\begin{aligned}
 P(HD = yes) &= \sum_{\alpha} \sum_{\beta} P(HD = yes \mid E = \alpha, D = \beta) P(E = \alpha, D = \beta) \\
 &= \sum_{\alpha} \sum_{\beta} P(HD = yes \mid E = \alpha, D = \beta) P(E = \alpha) P(D = \beta) \\
 &= 0.25 \times 0.7 \times 0.25 + 0.45 \times 0.7 \times 0.75 + 0.55 \times 0.3 \times 0.25 + 0.75 \times 0.3 \times 0.75 \\
 &= 0.49
 \end{aligned}$$

E=yes
0.7

D=Healthy
0.25

	Hd=yes
E=yes D=healthy	0.25
E=yes D=unhealthy	0.45
E=no D=healthy	0.55
E=no D=unhealthy	0.75


**El paciente tiene
ligeramente
mas probabilidad
de no tener
la enfermedad**

$$P(HD = no) = 1 - P(HD = yes) = 0.51$$

2. Alta presión (High Blood pressure)

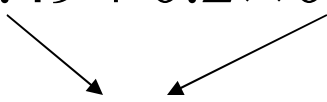
- Diagnostico comparando las probabilidades posteriores
 $P(HD=yes \mid BP=high)$ vs $P(HD=no \mid BP=high)$
- Se debe computar $P(BP=high)$

$$P(BP = High) = \sum_{\gamma} P(BP = High \mid HD = \gamma) P(HD = \gamma)$$

{yes, no} valores de **Heart disease** 

$$= 0.85 \times 0.49 + 0.2 \times 0.51 = 0.5185$$

Calculado con las probabilidades apriori



	Bp=high
HD=yes	0.85
HD=no	0.2

- La probabilidad posterior de que la persona tiene enfermedad del corazón es:

$$\begin{aligned} P(HD = yes \mid BP = high) &= \frac{P(BP = high \mid HD = yes)P(HD = yes)}{P(BP = high)} \\ &= \frac{0.85 \times 0.49}{0.5185} = 0.8033 \end{aligned}$$

$$P(HD = no \mid BP = high) = 1 - 0.8033 = 0.1967$$

**Cuando el paciente tiene
presión alta incrementa
El riesgo de sufrir
Enfermedad del corazón**

3. Alta presión, dieta saludable (Healthy diet) y ejercicio regular (regular exercise)

- Tarea para próxima clase!

Características

- Modelo grafico
- Construir la red puede ser costoso. Sin embargo, una vez construida la red, adicionar una nueva variable es directo
- Trabajan bien con datos perdidos (sumando o integrando las probabilidades)
- El modelo es un poco robusto a overfitting

